

E-Commerce Churn Prediction and Analysis

Presented By: Muhamad Farhan Budiana
JCDSBSDAM29 – 003

Table of Content.

01

Executive Summary.

Apa itu Churn dan Kenapa Penting?



02

Arah Analisa: Dari Masalah ke Solusi

Tujuan Utama Analisa Churn Prediction



03

Metode Analysis Untuk Menentukan Churn

Langkah Analitik yang Dilakukan



04

Perilaku Customer dan E-Commerce Sebagai Penentu Churn

Identifies primary drivers of business expansion, including innovation.



05

Model Machine Learning yang Diuji

Menelusuri Algoritma yang Paling Optimal Untuk Churn Prediction



06

Hasil Komparasi Model

Model Dengan Akurasi Mendeteksi Churn Terbaik



07

Threshold Tuning

Menyesuaikan Batas Prediksi untuk Efisiensi Intervensi



08

Interpretasi Fitur

Apa yang Paling Mempengaruhi Pelanggan untuk Churn?



09

Insight Bisnis & Dampak Finansial

Strategi Retensi Berdasarkan Risiko & Nilai Pelanggan



10

Kesimpulan & Rekomendasi

Dari Prediksi ke Aksi: Strategi Retensi yang Berdampak





Executive Summary

Apa itu Churn dan Kenapa Penting?

- **Churn** adalah saat dimana pelanggan berhenti menggunakan layanan.
- Dalam konteks **e-commerce**, churn berarti pelanggan tidak kembali belanja → hilangnya potensi pendapatan.
- **Dampak langsung**: kehilangan pendapatan dan berkurangnya Customer Lifetime Value (CLV).

15%

Churn Rate

Rp2.000.000/tahun

Rata2 Belanja

maka dari 100.000 pelanggan, ada 15.000 yang hilang →
potensi kehilangan Rp30 miliar per tahun

Key Achievements

Perusahaan perlu mendeteksi pelanggan berisiko churn lebih awal agar bisa melakukan intervensi.





Arah Analisa: Dari Masalah ke Solusi

Tujuan Utama Analisa Churn Prediction

- Membangun **model prediksi churn** untuk mengetahui pelanggan mana yang berisiko berhenti.
- Memberikan informasi yang bisa ditindaklanjuti oleh tim bisnis, seperti siapa yang perlu ditawarkan promo atau dihubungi lebih dulu.
- Fokus pada **Recall** agar sebanyak mungkin pelanggan churn bisa terdeteksi.
- Menyediakan analisis faktor-faktor utama yang memengaruhi churn.
- Menyusun rekomendasi **strategi retensi** berdasarkan hasil model dan data.





Metode Analisis Untuk Menentukan Churn

Langkah Analitik yang Dilakukan

Analisa ini mengikuti alur analitik berikut:



- **Data:** kumpulkan dan pahami data dan informasi pelanggan
- **Preprocessing:** melakukan pembersihan data dan siapkan fitur
- **Modeling:** Melatih beberapa algoritma untuk prediksi churn
- **Evaluation Models:** bandingkan performa model dengan metrik seperti *Recall* dan *F1 Score*
- **Insight dan Rekomendasi:** identifikasi faktor utama yang memengaruhi churn dan susun strategi retensi berdasarkan hasil model

Churn Prediction Dianalisa Dengan Berbagai Cara

Proyek ini menggunakan pendekatan klasifikasi untuk memprediksi apakah pelanggan akan churn atau tidak.

- **Metode utama yang dilakukan:**
- **Data Cleaning** → memastikan tidak ada data kosong atau tidak valid.
- **Feature engineering** → membuat fitur baru yang lebih informatif, seperti gabungan antara keluhan dan kepuasan.
- **Split data** → membagi data menjadi data latih dan data uji (80:20) secara stratified agar proporsi churn tetap seimbang.
- **Machine Learning** → mencoba beberapa algoritma seperti Logistic Regression, Random Forest, KNN, SVM, dan XGBoost.
- **Evaluations model** → membandingkan performa model menggunakan metrik seperti Accuracy, Precision, Recall, F1 Score, ROC AUC, dan PR AUC.
- **Result interpretation** → melihat fitur mana yang paling berpengaruh terhadap churn.
- **Business Recommendations** → menyusun strategi retensi berdasarkan hasil model dan insight data




Perilaku Customer dan E-Commerce Sebagai Penentu Churn

Keluhan dan Awal Hubungan Menentukan Masa Depan Pelanggan

Pelanggan yang pernah mengeluh memiliki churn rate lebih dari **35%**, dua kali lipat dibanding yang tidak mengeluh. Ini menunjukkan bahwa keluhan adalah sinyal awal risiko churn. Pelanggan yang churn memiliki tenure rata-rata hanya 3 bulan, jauh lebih pendek dibanding pelanggan yang bertahan (± 11 bulan).



- Artinya, pelanggan baru sangat rentan churn, terutama jika tidak puas sejak awal.



Kepuasan Penting, Tapi Reward Menjaga Mereka Tetap Bertahan

Semakin tinggi Satisfaction Score, semakin rendah churn rate → tren yang wajar. Namun, tetap ada pelanggan dengan skor 4–5 yang tetap churn menunjukkan bahwa kepuasan tidak selalu cukup.

Pelanggan yang tidak churn menerima cashback lebih tinggi dibanding yang churn. Ini menunjukkan bahwa **insentif finansial** seperti *cashback* efektif menjaga loyalitas.



Model Machine Learning yang Diuji

Menelusuri Algoritma yang Paling Optimal Untuk Churn Prediction

Logistic Regression	Menghitung kemungkinan churn berdasarkan kombinasi fitur. Mudah dijelaskan dan cepat dilatih, tapi kurang fleksibel untuk pola yang kompleks.
Random Forest	Membuat banyak pohon keputusan, lalu mengambil rata-rata prediksi.
K-Nearest Neighbors (KNN)	Model berbasis jarak antar pelanggan. Memprediksi churn berdasarkan perilaku pelanggan yang mirip.
Support Vector Machine	Mencari garis pemisah terbaik antara pelanggan churn dan tidak churn.
XGBoost	Model gradient boosting yang sangat populer dan kompetitif. Menggabungkan banyak pohon kecil secara bertahap untuk memperbaiki kesalahan prediksi sebelumnya.

Evaluasi Algoritma Paling Akurat

Accuracy	seberapa banyak prediksi yang benar dari total data. Cocok jika data seimbang, tapi kurang informatif saat data churn tidak seimbang
Precision	Mengukur seberapa tepat prediksi churn.
Recall	Mengukur seberapa banyak churn yang berhasil ditangkap. Dari semua pelanggan yang benar-benar churn, berapa yang berhasil diprediksi.
F1 Score	Keseimbangan antara precision dan recall. Tepat digunakan untuk kombinasi antara deteksi churn dan efisiensi outreach
ROC AUC & PR AUC	ROC AUC mengukur kemampuan model membedakan antara pelanggan churn dan tidak churn secara umum. PR AUC lebih cocok untuk kasus data tidak seimbang, seperti churn yang hanya sebagian kecil dari total pelanggan.

Hasil Komparasi Model

Model Dengan Akurasi Mendeteksi Churn Terbaik

Setelah pengujian, performa kelima model dibandingkan menggunakan metrik utama: *Accuracy*, *Precision*, *Recall*, *F1 Score*, *ROC AUC*, dan *PR AUC*.

XGBoost menunjukkan performa terbaik di semua metrik utama:

- **Akurasi tinggi** → prediksi keseluruhan tepat
- **Precision tinggi** → intervensi lebih efisien
- **Recall cukup tinggi** → banyak churn berhasil ditangkap
- **PR AUC & ROC AUC tertinggi** → model tetap kuat meski data churn tidak seimbang

Model	Accuracy	Precision	Recall	F1 Score	ROC AUC	PR AUC
Logistic Regression	80.74%	46.32%	79.26%	58.47%	87.71%	66.10%
Random Forest	94.42%	88.99%	77.04%	82.54%	95.82%	89.76%
KNN	88.97%	76.67%	51.11%	61.33%	88.68%	66.29%
SVM	90.11%	75.68%	62.22%	68.29%	91.50%	71.55%
XGBoost	94.93%	92.79%	76.30%	83.74%	96.33%	90.33%

Threshold Tuning


The background features a horizontal color gradient from purple on the left to blue on the right. It is decorated with several white geometric elements: a large vertical rectangle on the left, a smaller rectangle below it, and a complex shape on the right consisting of a vertical rectangle, a horizontal bar at the top, and another vertical rectangle below that.

Menyesuaikan Batas Prediksi untuk Efisiensi Intervensi

Model prediksi churn menghasilkan probabilitas, bukan langsung keputusan.

- Dengan threshold **default 0.5**, pelanggan dianggap churn jika probabilitas > **50%**.
- Namun, threshold bisa disesuaikan untuk mencapai tujuan bisnis tertentu:
- **Recall tinggi** → deteksi lebih banyak pelanggan berisiko
- **Precision tinggi** → intervensi lebih efisien, tidak banyak salah sasaran
- Dengan dilakukan **tuning threshold** untuk mencari titik optimal antara Recall dan Precision.
- Hasil terbaik ditemukan di threshold **0.35**, dengan **Recall 83.70%** dan **Precision 76.92%**.
- Artinya: kita bisa menangkap lebih banyak churn tanpa terlalu banyak false positives.

Trade-off Precision vs Recall pada Berbagai Threshold






Interpretasi Fitur

Apa yang Paling Mempengaruhi Pelanggan untuk Churn?

Model XGBoost tidak hanya memprediksi churn, tapi juga menunjukkan fitur-fitur yang paling berpengaruh.

- Top 5 fitur utama berdasarkan importance:
 1. **Tenure_Cashback (14.0%)** → kombinasi lama berlangganan dan jumlah cashback sangat menentukan loyalitas.
 2. **IsNewCustomer (12.7%)** → pelanggan baru jauh lebih rentan untuk churn, terutama di bulan-bulan awal.
 3. **Tenure (9.8%)** → semakin lama pelanggan bertahan, semakin kecil kemungkinan churn.
 4. **Complain (6.4%)** → keluhan adalah sinyal kuat ketidakpuasan dan risiko churn.
 5. **LowSatisfaction (4.3%)** → skor kepuasan rendah memperbesar kemungkinan churn, terutama jika tidak ditindaklanjuti.



Tiga Risiko Churn: Siapa yang Harus Diselamatkan?

Segmen Pelanggan	Karakteristik Utama	Risiko	Strategi Utama
Pelanggan Baru & Tidak Puas	IsNewCustomer = 1, LowSatisfaction = 1	● Tinggi	Onboarding intensif dan edukasi awal
Sering Mengeluh & Minim Cashback	Complain = 1, CashbackAmount rendah	● Sedang	Tindak cepat keluhan, evaluasi insentif
Loyal tapi Mulai Turun Kepuasan	Tenure tinggi, SatisfactionScore menurun	● Menengah	Survei berkala dan pendekatan personal

Segmentasi ini bukan sekadar klasifikasi, tapi menjadi dasar strategi retensi yang terarah dan efisien. Dengan memahami karakteristik tiap segmen, tim bisnis dapat:

Pelanggan Baru & Tidak Puas

- Kenapa penting: Pelanggan baru adalah aset jangka panjang, tapi mereka juga paling rentan churn jika tidak puas sejak awal.
- Risiko: Sangat tinggi — mereka belum punya ikatan emosional atau pengalaman positif.

Sering Mengeluh & Minim Cashback

- Kenapa penting: Keluhan adalah sinyal langsung dari pelanggan yang merasa tidak dihargai. Jika tidak ditangani, mereka akan churn.
- Risiko: Sedang — mereka masih aktif, tapi frustrasi.

Loyal tapi Mulai Turun Kepuasan

- Kenapa penting: Mereka sudah lama bersama kita, tapi mulai menunjukkan tanda-tanda lelah atau kecewa.
- Risiko: Menengah — churn bisa terjadi diam-diam.



Insight Bisnis & Dampak Finansial

Strategi Retensi Berdasarkan Risiko & Nilai Pelanggan

Risk Level	Total Value Lost	Customer Count	Avg Value per Customer
Low	\$121,984	659	\$185
High	\$18,972	106	\$179
Medium	\$4,711	24	\$196

Segmen Low punya jumlah pelanggan terbanyak, jadi wajar jika total kerugian paling besar meskipun nilai per pelanggan tidak ekstrem.

- Ini menunjukkan bahwa churn massal di segmen rendah tetap berdampak besar secara total.

Segmen Medium punya nilai rata-rata tertinggi, meskipun jumlahnya kecil.

- Ini bisa terjadi jika segmen ini berisi pelanggan yang aktif, loyal, atau punya pola pembelian tinggi tapi belum masuk kategori High.

Segmen High tidak selalu punya nilai rata-rata tertinggi.

- Bisa jadi mereka dipilih berdasarkan probabilitas churn tinggi, bukan nilai transaksi tertinggi. Jadi meskipun mereka berisiko, nilai per pelanggan tidak harus paling besar.



Kesimpulan & Rekomendasi

Dari Prediksi ke Aksi: Strategi Retensi yang Berdampak

Kesimpulan

- Model churn yang digunakan bukan hanya alat prediksi, tapi juga alat strategi bisnis.
- Dengan menggabungkan **probabilitas churn** dan **estimasi nilai pelanggan**, kita dapat:
 - Menyusun strategi retensi yang lebih tajam dan hemat biaya
 - Menghindari kerugian hingga \$145,000+ dari pelanggan berisiko
 - Mengarahkan campaign ke segmen yang paling berdampak

Rekomendasi Utama

1. Fokus pada Segmen High & Medium Risk


- Retensi personal, edukasi fitur, dan insentif terarah

2. Optimalkan Program Loyalitas untuk Segmen Low Risk

- Monitoring berkala dan penghargaan jangka panjang

3. Integrasikan Model ke Workflow CRM & Marketing

- Gunakan segmentasi risiko untuk otomatisasi campaign dan alokasi anggaran



Thank You!





Appendix

https://www.canva.com/design/DAG4W6r9FSw/8cSht9EhBDW3V1UzI_ZHOg/edit

<https://drive.google.com/drive/folders/1PITb78NtK9Ra6wOkQdXCIGltZkj29Ves>

<https://github.com/FarhanBud/E-Commerce-Customer-Churn>